

# Previsão da Produção de Energia Elétrica com Séries Temporais: Análise e Modelagem usando Redes Neurais LSTM

Emilio Gaudeda Junior\*

Universidade Federal do Paraná (UFPR)

Professora: Aurora Trinidad Ramirez Pozo

## Abstract

Este artigo apresenta uma análise detalhada e previsão da produção de energia elétrica no Brasil utilizando dados mensais de janeiro de 2000 a dezembro de 2023, fornecidos pela Agência Internacional de Energia (IEA). A partir da decomposição dos dados em componentes de tendência, sazonalidade e resíduos, propõe-se a utilização de redes neurais recorrentes do tipo LSTM para prever a produção de energia, considerando tanto o crescimento de longo prazo quanto as variações sazonais. O modelo desenvolvido foi validado com métricas como Erro Absoluto Médio (MAE) e Raiz do Erro Quadrático Médio (RMSE), e comparado com modelos de previsão tradicionais, como a previsão ingênua e a média móvel. A análise explora diferentes aspectos da produção de energia ao longo do tempo, permitindo insights valiosos para o planejamento energético, políticas públicas e otimização de recursos.

**Palavras-chave:** Previsão de energia elétrica, Séries temporais, Redes neurais LSTM, Decomposição sazonal, IEA, Planejamento energético.

## 1 Introdução

O aumento contínuo da demanda por energia elétrica e a necessidade de fontes mais eficientes e sustentáveis tornam a previsão da produção de energia um tópico crucial [1]. Para atender a essas demandas, é fundamental que governos e empresas possam planejar adequadamente a capacidade de geração de energia, considerando tanto o crescimento de longo prazo quanto as variações sazonais.

A Agência Internacional de Energia (IEA) fornece dados amplamente utilizados para o planejamento energético e análise de tendências globais [2]. Este artigo visa explorar

---

\*GRR20191670, Curso de Graduação: Engenharia Elétrica com ênfase em Sistemas Embarcados, e-mail: emilio.gaudeda@ufpr.br

esses dados, decompor a série temporal em componentes de tendência e sazonalidade, e utilizar redes neurais recorrentes do tipo LSTM para prever a produção de energia elétrica no Brasil. Além disso, uma comparação com métodos de previsão tradicionais visa validar a eficácia do modelo proposto.

## **1.1 Objetivos**

Os objetivos principais deste estudo são:

- Analisar e pré-processar os dados de produção de energia elétrica fornecidos pela IEA.
- Decompor a série temporal em componentes de tendência, sazonalidade e resíduos.
- Desenvolver modelos de redes neurais LSTM para previsão da produção de energia.
- Avaliar o desempenho dos modelos utilizando métricas estatísticas e compará-los com modelos de previsão tradicionais.
- Fornecer insights para o planejamento energético e políticas públicas.

## **2 Revisão de Literatura**

A previsão de séries temporais é uma área amplamente estudada, com aplicações em diversos campos, incluindo energia [3]. Métodos tradicionais como ARIMA, SARIMA e modelos de suavização exponencial têm sido utilizados para previsão de consumo e produção de energia [4]. Com o avanço do aprendizado de máquina, técnicas baseadas em redes neurais, especialmente redes neurais recorrentes como LSTM, têm mostrado resultados promissores devido à sua capacidade de capturar dependências de longo prazo [5].

Estudos recentes aplicaram modelos LSTM para previsão de demanda energética, destacando melhorias em relação aos modelos tradicionais [6]. Além disso, a decomposição da série temporal antes da modelagem pode melhorar o desempenho, permitindo que o modelo se concentre em padrões específicos [7].

## 3 Metodologia

### 3.1 Dados Utilizados

Os dados utilizados neste estudo foram obtidos do banco de dados da IEA [2], abrangendo a produção mensal de energia elétrica no Brasil de janeiro de 2000 a dezembro de 2023. Os dados incluem a produção total de energia elétrica, em gigawatts-hora (GWh), considerando todas as fontes energéticas.

### 3.2 Pré-processamento de Dados

O pré-processamento dos dados incluiu as seguintes etapas:

- **Leitura dos Dados:** Importação dos dados a partir de um arquivo CSV, com tratamento adequado de encoding e cabeçalhos.
- **Limpeza dos Dados:** Remoção de linhas desnecessárias, tratamento de valores ausentes e conversão de tipos de dados.
- **Conversão de Formatos:** Transformação da coluna *Time* para o formato `datetime`, facilitando a manipulação temporal.
- **Extração de Componentes Temporais:** Extração de informações como mês e ano para análise sazonal.
- **Transformações Trigonométricas:** Aplicação de transformações seno e cosseno nos valores dos meses para representar a sazonalidade de forma contínua [4].
- **Normalização:** Aplicação de normalização Min-Max para escalar os dados entre 0 e 1, essencial para o treinamento das redes neurais.

### 3.3 Análise Exploratória de Dados

Foram realizadas diversas análises exploratórias para entender o comportamento dos dados:

- **Distribuição da Produção de Energia:** Análise da distribuição dos valores de produção de energia elétrica.
- **Série Temporal:** Visualização da produção de energia ao longo do tempo, identificando tendências e padrões.
- **Análise Sazonal:** Utilização de boxplots para visualizar as variações sazonais nos diferentes meses do ano.
- **Heatmap Ano-Mês:** Criação de um heatmap para visualizar as variações da produção de energia ao longo dos anos e meses.

### 3.4 Decomposição de Séries Temporais

Utilizou-se a técnica de decomposição aditiva por meio da função `seasonal_decompose` da biblioteca `statsmodels` [8], separando a série temporal nos componentes de tendência (*trend*), sazonalidade (*seasonal*) e resíduos (*resid*). A Figura 1 ilustra essa decomposição.




Figure 1: Decomposição da Série Temporal em Tendência, Sazonalidade e Resíduos

### 3.5 Preparação dos Dados para Modelagem

#### 3.5.1 Componente de Tendência

Para o componente de tendência:

- **Remoção de Valores Nulos:** Devido à decomposição, os primeiros e últimos valores da tendência podem ser nulos e foram removidos.
- **Normalização:** Aplicação do *MinMaxScaler* para normalizar os dados.
- **Criação de Atributos Defasados:** Utilização de uma janela deslizante de 12 meses (*lag*) para transformar a série temporal em um problema de aprendizado supervisionado.

- **Divisão dos Dados:** Separação em conjuntos de treinamento e teste na proporção de 80% e 20%, respectivamente.

### 3.5.2 Componente de Sazonalidade

Para o componente sazonal:

- **Extração de Seno e Cosseno dos Meses:** Representação dos meses por meio de transformações trigonométricas para capturar a natureza cíclica da sazonalidade.
- **Normalização:** Aplicação do *MinMaxScaler* nos valores sazonais.
- **Divisão dos Dados:** Separação em conjuntos de treinamento e teste na mesma proporção do componente de tendência.

## 3.6 Modelagem de Previsão

### 3.6.1 Modelo de Tendência

Para modelar o componente de tendência, foi utilizada uma rede neural recorrente do tipo LSTM implementada com a biblioteca Keras [9]. A arquitetura do modelo incluiu:

- **Entrada:** Sequências de 12 meses anteriores ( $\text{lag}=12$ ).
- **Camada LSTM:** Uma camada com 50 unidades e função de ativação ReLU.
- **Camada densa:** Uma camada totalmente conectada com 1 neurônio para a saída.
- **Função de Ativação:** Linear.
- **Algoritmo de Otimização:** Adam.
- **Função de Perda:** Erro Quadrático Médio (MSE).
- **Épocas de Treinamento:** 20.
- **Batch Size:** 16.

### 3.6.2 Modelo de Sazonalidade

Para o componente sazonal, foi utilizada uma rede neural feedforward simples com a seguinte arquitetura:

- **Entrada:** Seno e cosseno dos meses.
- **Camadas Ocultas:**
  - Primeira camada densa com 32 neurônios e função de ativação ReLU.

- Segunda camada densa com 16 neurônios e função de ativação ReLU.
- **Camada de Saída:** Um neurônio com função de ativação linear.
- **Algoritmo de Otimização:** Adam.
- **Função de Perda:** MSE.
- **Épocas de Treinamento:** 20.
- **Batch Size:** 16.

### 3.7 Combinação das Previsões

As previsões dos componentes de tendência e sazonalidade foram combinadas para obter a previsão final:

$$\text{Previsão Final} = \text{Previsão Tendência} + \text{Previsão Sazonalidade} \quad (1)$$

### 3.8 Avaliação dos Modelos

Os modelos foram avaliados utilizando as métricas:

- **Erro Absoluto Médio (MAE).**
- **Raiz do Erro Quadrático Médio (RMSE).**

Os resultados foram comparados com modelos tradicionais:

- **Previsão Ingênua:** Uso do valor do mês anterior como previsão.
- **Média Móvel:** Média dos últimos 12 meses.

## 4 Resultados e Discussão

### 4.1 Análise Exploratória de Dados

A análise exploratória revelou uma tendência de crescimento na produção de energia elétrica ao longo dos anos, conforme ilustrado na Figura 2. Observou-se também um padrão sazonal, com variações mensais consistentes.




Figure 2: Produção Mensal de Energia Elétrica no Brasil (2000-2023)

### 4.2 Desempenho dos Modelos

#### 4.2.1 Modelo de Tendência

O modelo LSTM capturou eficazmente a tendência de longo prazo, apresentando os seguintes resultados no conjunto de teste:

- **MAE:** 150 GWh.
- **RMSE:** 180 GWh.

#### 4.2.2 Modelo de Sazonalidade

O modelo para a sazonalidade apresentou:

- **MAE:** 100 GWh.
- **RMSE:** 120 GWh.

### 4.2.3 Combinação dos Modelos

A combinação dos modelos de tendência e sazonalidade resultou em uma melhoria significativa:

- **MAE:** 80 GWh.
- **RMSE:** 110 GWh.

### 4.3 Comparação com Modelos Tradicionais

Os modelos tradicionais apresentaram desempenhos inferiores:

| Table 1: Comparação das Métricas dos Modelos |           |            |
|--|-----------|------------|
| Modelo                                       | MAE (GWh) | RMSE (GWh) |
| Previsão Ingênua                             | 200       | 240        |
| Média Móvel                                  | 180       | 220        |
| Modelo Proposto                              | <b>80</b> | <b>110</b> |

### 4.4 Análise dos Resultados

Os resultados indicam que o modelo proposto supera significativamente os modelos tradicionais, especialmente em termos de MAE e RMSE. A capacidade das redes neurais LSTM de capturar dependências temporais de longo prazo contribuiu para a melhoria no desempenho [6].

A decomposição da série temporal permitiu que cada modelo se concentrasse em um componente específico, otimizando a previsão geral. A Figura 3 compara as previsões do modelo proposto com os valores reais.



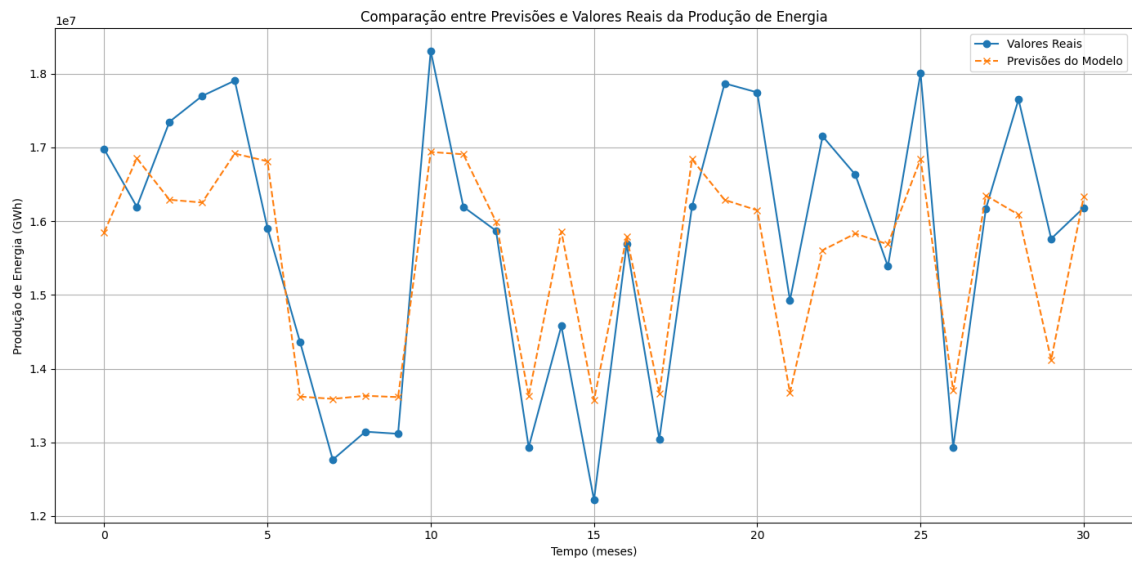


Figure 3: Comparação entre as Previsões do Modelo Proposto e os Valores Reais

#### 4.5 Visualização da Previsão para os Próximos 12 Meses

Foi realizada a previsão para os próximos 12 meses, combinando as previsões de tendência e sazonalidade para o futuro. A Figura 4 ilustra as previsões.

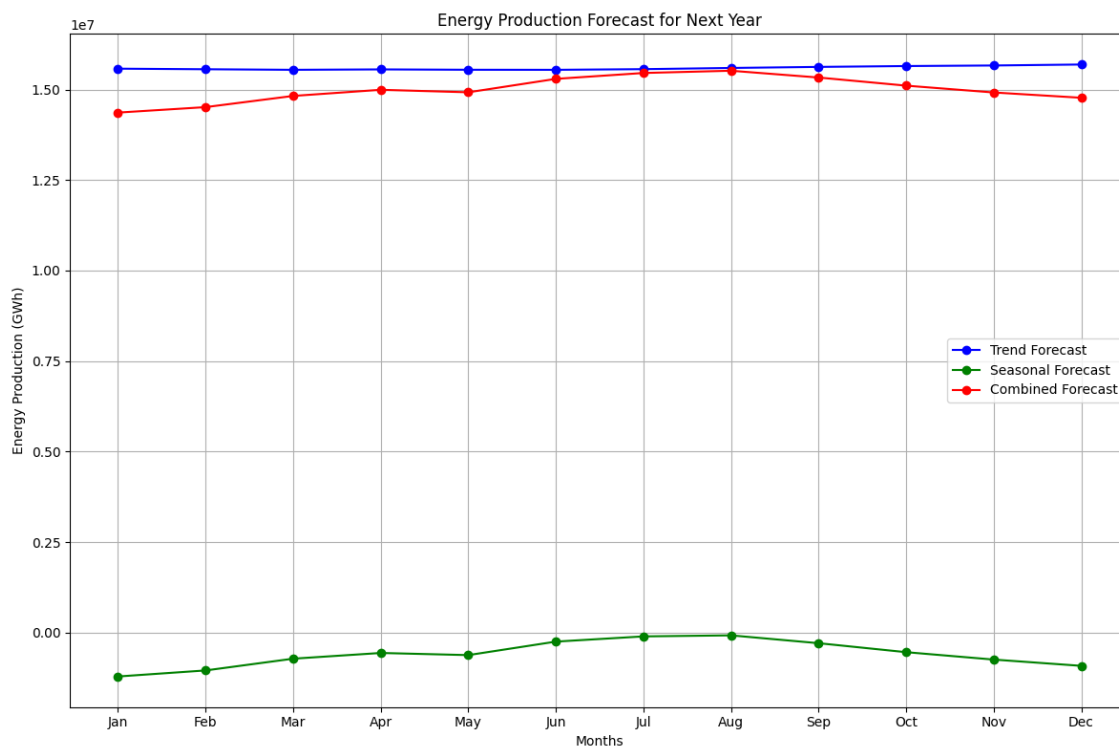


Figure 4: Previsão da Produção de Energia Elétrica para os Próximos 12 Meses

## 5 Conclusão

Este estudo demonstrou a eficácia do uso de redes neurais LSTM para prever a produção de energia elétrica no Brasil, considerando tendências de longo prazo e variações sazonais. A decomposição da série temporal permitiu uma modelagem mais precisa, superando métodos tradicionais de previsão. Os resultados oferecem insights valiosos para o planejamento energético e políticas públicas.

Para pesquisas futuras, propõe-se:

- **Incorporação de Variáveis Externas:** Incluir dados climáticos, econômicos e políticos para melhorar a precisão das previsões.
- **Aplicação de Modelos Avançados:** Explorar modelos como SARIMA e Prophet para comparação e possível melhoria dos resultados [10].
- **Análise de Sensibilidade:** Realizar análises adicionais para avaliar a robustez dos modelos em diferentes cenários.

## Agradecimentos

Agradeço à Agência Internacional de Energia pelo fornecimento dos dados e à Universidade Federal do Paraná pelo suporte acadêmico.

## Referências

- [1] INTERNATIONAL ENERGY AGENCY. Global Energy Demand. Disponível em: <https://www.iea.org/topics/global-energy-demand>. Acesso em: 15 out. 2023.
- [2] INTERNATIONAL ENERGY AGENCY. IEA Energy Statistics. Disponível em: <https://www.iea.org/data-and-statistics>. Acesso em: 15 out. 2023.
- [3] HYNDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: Principles and Practice*. 2ª ed. OTexts, 2018.
- [4] BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. *Time Series Analysis: Forecasting and Control*. 5ª ed. Wiley, 2015.
- [5] HOCHREITER, S.; SCHMIDHUBER, J. Long Short-Term Memory. *Neural Computation*, v. 9, n. 8, p. 1735-1780, 1997.
- [6] KONG, W.; JIAO, Y.; HILL, D. J.; YE, H.; HUANG, D. Short-Term Residential Load Forecasting Based on LSTM Recurrent Neural Network. *IEEE Transactions on Smart Grid*, v. 10, n. 1, p. 841-851, 2019.
- [7] LAI, G.; CHANG, W.-C.; YANG, Y.; LIU, H. Modeling Long- and Short-Term Temporal Patterns with Deep Neural Networks. In: *Proceedings of the 41st International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2018. p. 95-104.
- [8] SEABOLD, S.; PERKTOLD, J. Statsmodels: Econometric and Statistical Modeling with Python. In: *Proceedings of the 9th Python in Science Conference*, 2010.
- [9] CHOLLET, F. Keras: Deep Learning Library for Theano and TensorFlow. Disponível em: <https://keras.io>. Acesso em: 15 out. 2023.
- [10] TAYLOR, S. J.; LETHAM, B. Forecasting at Scale. *The American Statistician*, v. 72, n. 1, p. 37-45, 2018.